

THIAGO ROSCIA CERDEIRO DE LIMA

**SOBRE APRENDIZAGEM DE MÁQUINAS APLICADA A
SISTEMAS DE DETECÇÃO DE INTRUSÃO EM REDE
BASEADOS EM ANOMALIAS**

CURITIBA

2015

THIAGO ROSCIA CERDEIRO DE LIMA

**SOBRE APRENDIZAGEM DE MÁQUINAS APLICADA A
SISTEMAS DE DETECÇÃO DE INTRUSÃO EM REDE
BASEADOS EM ANOMALIAS**

Monografia apresentada para obtenção do
Grau de Bacharel em Ciência da Com-
putação pela Universidade Federal do Pa-
raná.

Orientador: Prof. Dr. Luis Allan Kunzle

CURITIBA

2015

SUMÁRIO

RESUMO	iii
1 INTRODUÇÃO	1
2 SIGNATURE-BASED IDS	3
3 ANOMALY-BASED IDS (A-NIDS)	4
3.1 Técnicas Estatísticas	4
3.2 Técnicas Baseadas em Conhecimento	5
3.3 Técnicas de Machine Learning	5
3.4 Combinação de Classificadores	6
3.4.1 Classificadores Híbridos	6
3.4.2 Classificadores em Cascata	6
3.4.3 Composição de Classificadores	7
4 SISTEMAS A-NIDS FUNCIONAIS	8
4.1 Arquitetura	8
4.2 Comercialmente	9
5 DADOS	10
5.1 Origem dos Dados	10
5.1.1 Cabeçalho de pacote	11
5.1.2 Corpo de pacote	11
5.2 Conjuntos de Características	12
5.2.1 Conexões múltiplas	12
5.2.2 Única conexão	12
5.2.3 KDD Cup 99	13
5.3 Pré-processamento	13

5.3.1	Derivação	13
5.3.2	Alternativas de processamento	14
6	ANÁLISE DE TRABALHOS RELACIONADOS	16
6.1	Processando grandes quantidades de dados	17
6.1.1	Support Vector Machine	17
6.1.2	Árvore de Decisão	17
6.2	Aumentado a velocidade de processamento	18
7	TESTES	19
7.1	Weka	19
7.2	Avaliação de Performance	19
7.3	Impacto de modelos representativos	22
7.4	Impacto da imprevisibilidade	22
7.5	Impacto da seleção de atributos	22
8	CONCLUSÃO	24
	BIBLIOGRAFIA	24

RESUMO

O aumento da resolução espacial de imagens é de grande interesse para várias aplicações. Dentro da biometria isto pode implicar no aumento da performance dos algoritmos e do relaxamento do grau de cooperação necessário dos indivíduos a serem identificados. A super-resolução surge como meio de realização desta tarefa, alternativa à aquisição de novos sensores de custo mais elevado. O método consiste em combinar os dados contidos em diversas vistas de uma mesma cena, sejam elas capturadas por um único ou múltiplos sensores, a fim de gerar um quadro de maior resolução como saída. Sistemas que utilizam informação 3D também podem ser beneficiados, pois quando aplicado a imagens de profundidade, a super-resolução cria nuvens de pontos de maior densidade. Neste trabalho foi avaliada a possibilidade da aplicação de técnicas de super-resolução em sistemas biométricos 2D e 3D, com ênfase em sistemas de reconhecimento facial. No caso 2D, um algoritmo capaz de obter resultados melhores que a interpolação bicúbica foi implementado. Para 3D, uma análise visual nos resultados do nosso algoritmo aplicado em objetos rígidos mostrou potencial para aplicações práticas.

Palavras-chave: Super-Resolução, Imagens de Profundidade, Biometria, Reconhecimento Facial

CAPÍTULO 1

INTRODUÇÃO

A Internet representa, atualmente, não apenas mais uma ferramenta de uso diário, mas um completo ambiente utilizado por cidadãos para armazenamento de arquivos pessoais, por bancos para efetuar transações bancárias e por governos para trocas de informações preciosas. Assim como é possível se conectar de uma máquina pessoal a um servidor *web*, é possível fazer o contrário. Qualquer máquina conectada a uma rede está teoricamente sujeita ao acesso de fora. Roteadores e sistemas operacionais atuais estão equipados com ferramentas básicas para prevenir acesso não autorizado ao computador. Ainda assim, há pessoas dedicadas a burlar tais proteções. Alguns desses invasores conseguem copiar arquivos, instalar *malware* e até ganhar controle sobre o sistema sem serem notados pelo dono.

A fim de cobrir esse ponto cego, foram criados sistemas de detecção de intrusão, ou IDS (*intrusion detection systems*). Seu objetivo é reconhecer comportamentos incomuns dentro de uma rede. No meio acadêmico, muitos artigos foram publicados explorando algoritmos de Machine Learning nesta aplicação.

Existem diversos tipos de ataques e diferentes protocolos de comunicação, mas o problema de se detectar uma intrusão pode ser simplificado em um problema de classificação binária do comportamento do sistema, onde os dois possíveis resultados seriam "normal" ou "intrusivo". Existem duas "escolas de pensamento" bem definidas no meio acadêmico acerca do assunto:

1. *Signature-based*, ou baseado em assinatura. Esse é o método padrão e atualmente o único utilizado comercialmente. Ele possui baixa adaptabilidade a novas ameaças.
2. *Anomaly-based*, ou baseado em anomalia. Ainda uma área de estudo, possui alta taxa de Falso-Positivo, mas boa adaptabilidade.

Este artigo dará, posteriormente, foco aos conceitos e desenvolvimento de algoritmos de

Machine Learning e Sistemas de Detecção de Intrusão em Rede baseados em Anomalia (A-NIDS).

CAPÍTULO 2

SIGNATURE-BASED IDS

Apesar de não ser o foco deste artigo, vamos descrever brevemente os sistemas baseados em assinatura, a fim de comparação com os métodos nos quais vamos nos aprofundar.

Sistemas baseados em assinatura têm sido os mais bem sucedidos para detecção de intrusão até hoje. A ideia é comparar o tráfego da rede com padrões de comportamento conhecidos durante certos ataques. O maior problema é a ineficiência em detectar ataques novos.

Os primeiros sistemas utilizavam apenas o método de reconhecimento de padrão. Essa técnica possui um banco de dados preenchido com assinaturas de cada ameaça conhecida. Um evento malicioso é detectado se o atual estado da rede se iguala a uma assinatura. Como ele tenta comparar todas as assinaturas e a quantidade de dados transmitidos simultaneamente cresce a cada ano, o custo computacional tornou-se muito alto.

Uma segunda técnica é o método de *implication rules*, ou regras de inferência. Ela fornece um conjunto de regras que descrevem eventos conhecidos que podem inferir o acontecimento de um a intrusão. De qualquer modo, IDS de assinatura geralmente necessita de um humano capacitado, que cria um novo conjunto de regras toda vez que um novo tipo de ataque surge, para adquirir modelos de tráfego.

Daí surge a motivação para se utilizar técnicas de *data mining* em sistemas de assinatura. Elas provêm um modo de aumentar a automação na hora de construir e ajustar o modelo. Eles podem adaptar os modelos à medida que acessam tráfego de rede contendo novas ameaças ou detectando diferentes versões de um ataque conhecido. Ainda assim, é impossível identificar comportamentos maliciosos completamente desconhecidos.

CAPÍTULO 3

ANOMALY-BASED IDS (A-NIDS)

A técnica de detecção de anomalia analisa o atual comportamento da rede para checar se corresponde ou não a um comportamento normal. O maior benefício desse método é a habilidade de identificar novos ataques com sucesso. A desvantagem é a alta taxa de Falso Positivo. Ao invés de requerer um novo modelo a ser adaptado, sistemas baseados em anomalia necessitam de dados de tráfego de rede sem livres de ataques. *Data mining* também tem sido utilizado em sistemas baseados em anomalia, junto a outros métodos estatísticos e de *Machine Learning* (aprendizado de máquina).

As diferentes técnicas podem ser agrupadas em três categorias, de acordo com o processamento envolvido: estatístico, knowledge-based (baseado em conhecimento) ou algoritmos de aprendizado de máquina.

3.1 Técnicas Estatísticas

Um modelo de probabilidade de um determinado comportamento é criado a partir da atividade capturada do tráfego de rede, tal como taxa de tráfego, número de pacotes e quantidade de endereços de IP distintos.

Ele não requer conhecimento prévio pois está capacitado a aprender o comportamento normal a partir de observações sem ataques. Outro benefício das técnicas estatísticas é a possibilidade de identificar, com precisão, atividades maliciosas que ocorrem ao longo de períodos de tempo mais extensos. Por outro lado, nem todos os possíveis comportamentos conseguem ser modelados e o equilíbrio entre taxas de Falso Positivo e Falso Negativo dependem fortemente na configuração correta dos parâmetros.

3.2 Técnicas Baseadas em Conhecimento

Também chamados de expert systems, sistemas baseados em conhecimento são implementados criando-se um conjunto de regras de classificação para categorizar os dados. O modelo é geralmente criado por um humano experiente no campo da aplicação. Esse tipo de sistema não aponta novas atividades inofensivas como sendo maliciosas, garantindo, assim, um número reduzido de Falso Positivo. Por essa razão, o conjunto de regras precisa ser específico o suficiente e, apesar de ser possível atingir um certo nível de automatização usando uma máquina de estados finitos, requer grande conhecimento sobre o comportamento da rede e tempo significativo para ser desenvolvido.

3.3 Técnicas de Machine Learning

Métodos de aprendizado de máquina exigem um conjunto de dados categorizados para treinar o comportamento esperado do modelo. A característica principal dessa técnica é a habilidade de adaptar suas regras de classificação à medida que novos dados são recebidos. Isso garante pouca necessidade por intervenção humana, uma vez funcionando. O lado ruim do aprendizado de máquina é o alto custo computacional. Os algoritmos mais populares usados em A-NIDS são:

- Rede Bayesiana – cria uma rede de relações de probabilidade entre características
- Modelos de Markov – compara a probabilidade dos dados observados com um threshold definido
- Redes neurais – cria uma rede de perceptrons com habilidade de se adaptar
- Lógica Fuzzy – enxerga características como variáveis fuzzy e classifica com base em valores contínuos
- Algoritmos Genéticos – deriva regras de classificação e seleciona as características mais discriminantes

- Support Vector Machines – encontra um hiperplano que eficientemente separa ambas as opções de classificação
- Árvores de Decisão – cria uma árvore onde cada folha representa uma classe e arestas correspondem a diferentes valores de atributos
- Clustering – algoritmo não-supervisionado que agrupa dados com base em suas similaridades.

3.4 Combinação de Classificadores

Como cada método possui seus pontos fortes e pontos fracos. Uma ideia bastante estudada no meio acadêmico é a combinação de classificadores. Tais combinações podem se dar de diversas maneiras, como por exemplo: Classificadores Híbridos, Composição de Classificadores ¹ e Classificadores em Cascata.

3.4.1 Classificadores Híbridos

Um classificador híbrido consiste de dois componentes. O primeiro pré-processa o dado de entrada e envia ao segundo classificador, que chega ao resultado final. O primeiro componente de classificadores híbridos pode ser usado tanto como uma técnica de clustering para achar as classes que o segundo componente utilizará para categorizar os dados; quanto como um otimizador de performance para o segundo modelo, que corresponde ao método *integrado*.

3.4.2 Classificadores em Cascata

Pode ser considerado uma extensão dos classificadores híbridos, podendo consistir de inúmeros classificadores, onde o n-ésimo classificador utiliza como entrada os dados rejeitados pelo classificador anterior, ou seja, que não atingiram um grau de certeza satisfatório. Esse método foi analisado mais a fundo e testado a fim de comparar a agilidade e precisão em uma base de dados própria.

¹Tradução livre do termo em inglês Ensemble Classifiers.

3.4.3 Composição de Classificadores

Uma composição de classificadores pode ser obtida usando-se técnicas fracas de aprendizado (geralmente mais rápidas). Cada classificador é treinado usando um subconjunto distinto dos dados. A base de testes é, então, processada por todos eles e, finalmente, categorizados pela maioria.

CAPÍTULO 4

SISTEMAS A-NIDS FUNCIONAIS

O estudo feito em [?] apresenta sistemas A-NIDS divididos em duas categorias: comerciais e de pesquisa. Sistemas comerciais geralmente trabalham com um núcleo baseado em assinatura, enquanto sistemas de pesquisa protótipos e metodologias inovadoras.

4.1 Arquitetura

Enquanto alguns detalhes de implementação podem variar, a base da esquematização de um A-NIDS é como apresentado em [?]:

- Aquisição de dados de tráfego – coleta informação sobre os quadros da rede para processamento futuro.
- Gerador de características do tráfego – extrai características do tráfego capturado. Tais características podem ser classificadas como "baixo nível" (obtidas diretamente do dado bruto), "alto nível" (deduzidas de um processamento subsequente), "pacote" (coletadas de cabeçalhos de pacotes), "fluxo" (contendo informação das conexões) e "payload" (obtidos da carga do pacote).
- Detector de incidente – identifica atividades intrusivas. Pode ser tanto baseado em assinatura quanto em anomalia.
- Gerador de modelo de tráfego – contém informação base usada para guiar o detector de incidente.
- Gerenciamento de resposta – inicia manobras para superar uma intrusão em potencial. É inicializado pelo detector de incidente.

4.2 Comercialmente

Um dos primeiros projetos de detecção de anomalia a ser amplamente conhecido foi o SPADE, um plugin para o Snort que analisava transferência de pacotes procurando comportamentos fora do comum. Alternativamente, Stealthwatch utilizava detecção de anomalia baseada em fluxo.

Sistemas recentes usam uma arquitetura distribuída utilizando sensores e um console central para gerenciar o processo de detecção. Esse é o caso do DeepSight, que usa um método estatístico. A maioria dos sistemas comerciais utilizam um módulo de detecção baseado em assinatura aliado com um núcleo baseado em anomalia. Todos esses sistemas se enquadram na categoria de classificadores híbridos.

CAPÍTULO 5

DADOS

Os passos mais relevantes para o modelamento de dados de um NIDS são os seguintes:

1. Criação da base – identifica dados categorizados (normal ou anômalo) representativos para treino e teste. Categorização de tráfego de rede pode ser uma tarefa difícil e longa, que geralmente envolve um especialista.
2. Construção de características – cria características com maior discriminabilidade. Tais características podem ser construídas por um humano ou por algoritmos de aprendizado de máquina.
3. Redução – também chamado de "seleção de características", diminui a dimensionalidade da base de dados descartando características irrelevantes ou redundantes. Usado para atenuar a "Maldição da Dimensionalidade"¹.

5.1 Origem dos Dados

A escolha de informações da rede é amplamente afetada pelos requisitos de detecção ao se projetar o sistema. É possível ter sistemas de detecção específicos, utilizando um conjunto de características limitado. Para um sistema mais genérico, o ideal seria utilizar detectores separados utilizando conjuntos de características distintos, um para cada especificidade. Dependendo da origem desses dados, têm-se algumas vantagens e desvantagens. Técnicas para análise de conteúdo ainda não estão tão concretizadas quanto as que extraem características de cabeçalhos. Assim como analisar conteúdo do lado do cliente ainda é um campo não tão estudado quanto o lado do servidor numa perspectiva de A-NIDS. Técnicas do lado do cliente almejam detectar ameaças em aplicações web, como *drive-by downloads*, *cross-site scripting* e trechos maliciosos de JavaScript.

¹*Curse of Dimensionality*: Ao se usar muitas características, supostamente se obtém baixa precisão.

5.1.1 Cabeçalho de pacote

Características obtidas através de cabeçalhos de pacotes têm a qualidade de serem rápidos, sem exigir muito processamento ou memória, e evitarem preocupações legais acerca de análise de dados da rede. O conjunto de característica mais simples contém características básicas extraídas dos cabeçalhos. Essas características podem ser usadas para apontar pacotes individuais que são anômalos quando comparados ao modelo de treino; ou como um processo de filtragem para que apenas pacotes incomuns sejam usados por algoritmos de detecção posteriores. Entretanto, pacotes individuais não podem ser usados para identificar padrões incomuns durante um grande período. Existem ataques que contém cabeçalhos normais quando analisados individualmente, enquanto sua repetição durante um certo tempo pode ser considerada anômala. Um exemplo seria o ataque de negação de serviço, popularmente conhecido como *DoS*.

5.1.2 Corpo de pacote

Quando ataques são destinados a aplicações, os bytes maliciosos estão dentro do corpo do pacote e, portanto, as técnicas baseadas em cabeçalho não podem ser usadas. Isso representa um defeito considerável, principalmente porque diversos ataques da atualidade não são direcionados à rede em si, mas a aplicações conectadas a ela.

NIDS devem utilizar características baseadas em conteúdo, extraídas do corpo dos pacotes, para detectar tais tipos de ataques, uma vez que cabeçalhos podem aparentar completamente normais. Análise de conteúdo é computacionalmente mais cara do que análise de cabeçalho porque requer uma inspeção mais profunda do pacote. Ela lida com uma variedade de tipo de conteúdo (pdf, jpg, HTML), compressão, e métodos que encobrem dados. Entretanto, o benefício da análise do corpo é ter acesso a todos os bytes transferidos entre os aparelhos na rede, permitindo a construção de um rico conjunto de características baseadas em conteúdo para detecção de anomalia.

Como análise de conteúdo possui uma alta complexidade, diversos métodos focam em pequenos subconjuntos de conteúdo, como requisições HTTP ou apenas o JavaScript de um conteúdo baixado. Métodos baseados em anomalia não tentam comparar assinaturas

de malware conhecido, mas podem aplicar heurísticas, como Casamento de Padrões para detectar a presença de código shell.

5.2 Conjuntos de Características

5.2.1 Conexões múltiplas

Grande parte dos NIDS analisados em [?] usam dados de rede referentes a fluxo ou sessão. Características são construídas a partir do fluxo. O método mais popular é o de cabeçalho de pacotes utilizando características derivadas de múltiplas conexões (MCD). Essas características são geralmente divididas usando média, desvio padrão, e porcentagem de fluxos, cobrindo múltiplas sessões. NIDS baseados em anomalia que utilizam essas características são capazes de discernir entre atividade normal da rede e tráfego incomum como *DoS* e *scanning*.

características MCD são geralmente extraídas a partir de conexões dentro de um intervalo de tempo. A maioria das características de MCD são baseadas em volume, como o a quantidade de conexões a um endereço de IP e porta em um espaço de tempo. Portanto, características derivadas de múltiplas conexões podem ser facilmente usados para detectar volumes excessivos de tráfego relacionados a *DoS* e *probing*. Como pacotes anômalos individuais não suprem o valor baseado em volume, eles podem ser ignorados.

5.2.2 Única conexão

Características derivadas de conexões individuais (SCD) são utilizadas para detectar comportamento anômalo dentro de uma única sessão. Elas podem apontar um protocolo inesperado, tamanhos incomuns de dados, timestamp não condizente, ou sequências incomuns de *flags* de TCP. Portanto, características SCD permitem detecção de uso anômalo da rede por *backdoors*, túnel HTTP e afins.

As características SCD fornecem contexto que pode ser usado para encontrar anomalias não contextuais. Por exemplo, se a temporização de pacotes dentro de uma porta monitorada não se encaixa com um perfil esperado, um alerta pode ser disparado, uma

vez que pode se tratar de um protocolo de tunelamento.

5.2.3 KDD Cup 99

O KDD Cup 99 se trata de uma base dados para uso livre. Ela possui 32 características quantitativas e 9 qualitativas, junto a tráfego normal e ataques de *probing*, negação de serviço, *user to root* e *remote to local*. Tais características foram construídas por um especialista e envolvem informações de mais alto nível, como o número de tentativas de login sem sucesso, se acesso root ao terminal foi conseguido, e o número de operações de criação de arquivo.

Considierando que o KDD Cup 99 já tem mais de 15 anos, é provável que essas características não sejam mais úteis para detectar os tipos de ataques recentes na realidade do fluxo de dados na rede atualmente. Para se detectar ameaças atuais, é necessário construir características baseadas em conteúdo novas, uma vez que o conteúdo em si mudou.

5.3 Pré-processamento

Como anteriormente apontado, sistemas baseados em anomalia estão sujeitos a uma alta taxa de Falso Positivo. Apenas 1% sequer de Falso Positivo resulta em um número absurdo de falsos alertas. Deve-se ter em mente que servidores lidam com centenas de conexões simultâneas e inúmeros pacotes a cada centésimo de segundo.

O pré-processamento de dados é, então, exigido para atingir uma melhor performance na detecção de intrusão. O pré-processamento converte tráfego de rede em uma série de ocorrências, onde cada uma é representada por um vetor de características. As informações seguintes acerca dos dados e características foram baseadas nos estudos presentes em [?].

5.3.1 Derivação

Diferentes tipos de características que podem ser usados em NIDS baseados em anomalia foram cobertos em [?]. Cada tipo de característica é derivada de vários métodos de pré-

processamento, incluindo organizar pacotes em fluxos, analisar conteúdo de aplicações em busca de campos de interesse ou percorrer cabeçalhos de cada pacote. A derivação do potencial conjunto de características é um passo essencial para o NIDS baseado em anomalia. Analogamente, pré-processamentos subsequentes podem ajudar ainda mais a aumentar a eficiência do NIDS.

Métodos de pré-processamento de mineiração de dados podem ser usados, incluindo transformação, redução e discretização de dados, como os apresentados em [?]. Uma técnica de redução geralmente utilizada é a *Principal Component Analysis*. PCA tem se mostrado útil para redução da dimensionalidade dos dados, consequentemente reduzindo o custo computacional do sistema de detecção

Para eliminar características redundantes, diversos algoritmos automatizados para seleção de características também existem, resultando em redução de dados similar. Tais métodos de redução de dados fornecem um meio preciso para a conversão de um conjunto candidato para o conjunto final de características. É possível que métodos automáticos de redução possam melhorar ainda mais o NIDS, apesar de que alguns sistemas são construídos apenas se baseando no conhecimento de um especialista para construir conjuntos de características significativos.

5.3.2 Alternativas de processamento

Considerando métodos que almejam maior automatização no momento do processamento dos dados e características, existem duas ferramentas aparentemente promissoras: N-grams e libAnomaly. N-grams pode ser usado com algoritmos de seleção automática de características, enquanto o libAnomaly se trata de uma biblioteca livre para modelos de pré-processamento de dados.

No N-grams, perfis são construídos para diferentes tipos de arquivos, calculando as distribuições de frequência de byte. O NIDS compara, então, o tráfego observado com os perfis usando Distância Manhattan. N-gram é geralmente usado para analisar requisições ao servidor. É útil em detectar padrões anômalos, como código shell dentro de protocolos estruturados de aplicações, sem exigir supervisão muita supervisão.

O foco do libAnomaly, por sua vez, é construir um punhado de modelos representando a transferência normal de dados entre usuário e aplicação web. Requisições maliciosas provavelmente serão apontadas como anômalas quando comparadas com um ou mais modelos, pois geralmente se diferem de requisições normais de alguma forma.

Embora a intenção é que NIDS sejam completamente automáticos, sua criação e adaptação requerem um especialista. Mesmo o N-grams necessita de auxílio em algumas áreas da rede. LibAnomaly também requer experiência significativa para selecionar quais campos dentro da rede devem ser modelados. Por outro lado, detecção usando cabeçalhos de pacotes requerem menos conhecimento. Técnicas de mineiração de dados podem ser usados para derivar características de cabeçalhos MCD para detectar algumas ameaças. O conjunto de características em potencial poderá, então, ser processado no estágio de seleção de característica. Essas técnicas automatizadas garantem que as características disponíveis mais discriminantes sejam escolhidas.

CAPÍTULO 6

ANÁLISE DE TRABALHOS RELACIONADOS

NIDS baseado em anomalia têm se mostrado um a área de estudo promissora, mas ainda necessita de bastante pesquisa. Analisando os dados de artigos publicados entre os anos 2000 e 2007 e as diferentes técnicas utilizadas [?], é possível extrair algumas inferências.

- A maioria dos artigos se baseia no uso de classificadores unitários, apesar de que o uso de classificadores híbridos tem aumentado durante os últimos anos. Classificadores compostos são usados por poucos.
- Os algoritmos mais estudados para detecção de intrusão foram SVM e KNN. Quanto a classificadores híbridos, o método *integrado* é o mais popular.
- A utilização de seleção de atributos têm crescido com o tempo. Enquanto em 2003 apenas um quarto dos estudos analisados por [?] utilizava essa técnica, em 2007 foi o caso de 9 dentre 11. Ou seja, apenas dois ([?], [?]) não utilizaram.
- Como há poucas bases de dados públicas para detecção de intrusão, a maioria dos estudos se baseia nas bases KDD Cup 99 e DARPA 1998.

Quanto aos dados, as técnicas pioneiras costumavam criar modelos considerando todo o corpo do pacote. Entretanto, eles separavam as instâncias com base no tamanho do pacote e portas de destino, diminuindo o contexto de cada modelo. Técnicas posteriores levam em consideração partes específicas do conteúdo do pacote. Aparentemente, anomalias mais sutis podem ser detectadas a uma taxa menor de Falso Positivo quando usando um contexto mais específico.

Dois artigos recentes trouxeram implementações promissoras a respeito de sistemas de detecção de anomalia. Um deles ([?]) apresenta um algoritmo inteligente e o outro ([?]) mostra o ganho de performance ao se programar o sistema diretamente em uma placa FPGA.

6.1 Processando grandes quantidades de dados

A simulação apresentada em [?] usou o a base do KDD Cup 99. O algoritmo funciona pré-processando os dados de treino e teste e gerando uma solução inicial aleatória. A solução é atualizada a cada iteração do algoritmo. Enquanto um limite não é satisfeito, são utilizados Support Vector Machine (SVM) e Simulated Annealing (SA) para selecionar o melhor conjunto de características. Por conseguinte, Árvore de Decisão e SA são usados para aumentar a precisão do teste e construir regras de decisão. No final, a melhor precisão e as melhores características e regras de decisão são anunciadas.

Nos testes descritos no artigo, após a seleção de atributos, foram utilizados 23 durante o processo de classificação. O algoritmo conseguiu atingir uma precisão de 99,6%, o que representa um grande ganho quando comparado a outros resultados até o momento.

6.1.1 Support Vector Machine

SVM trabalha mapeando a base de treino em um espaço vetorial de maior dimensionalidade para aumentar a discriminação. Ele se baseia em minimizar o risco estrutural. Os dados de entrada são mapeados por uma *função núcleo*, a qual é geralmente escolhida entre *linear*, *polinomial*, *sigmoide* ou *radial basis*. A última é preferida no uso em SVM por sua capacidade de lidar com dados de alta dimensionalidade. SA é aplicado para escolher os melhores valores para os parâmetros usados na função *radial basis*.

6.1.2 Árvore de Decisão

DT é um método de classificação baseado em um algoritmo guloso, utilizando uma estratégia de divisão e conquista. Ele cria uma árvore de decisão contando um nó raiz, que é usado para selecionar o atributo com a informação de maior valor; nós internos, que correspondem às características; arestas, que são os possíveis valores de cada característica; e folhas, que contêm a classe a ser atribuída ao caso de teste.

6.2 Aumentado a velocidade de processamento

Enquanto o algoritmo anterior pretende otimizar apenas a precisão, o estudo apresentado em [?] foca em na aceleração do processo de classificação. Aqui também foi utilizado SVM para implementar o A-NIDS, mas dessa vez diretamente em um FPGA, fazendo uso de seu potencial de processamento paralelo.

Foram propostas três arquiteturas diferentes.

1. *Heterogeneous Baseline Classifier* – O objetivo é explorar os requerimentos de precisão dos atributos. Ele tenta maximizar paralelização enquanto mantém a relação entre blocos de processamento digital e blocos lógicos.
2. *Fit Cascade Chain* – Aproveita o potencial de aritmética customizada oferecido pelo FPGA para criar uma cascata com duas precisões aritméticas diferentes. Primeiro um classificador de baixo custo e alta vazão com baixa precisão é usado. Somente os dados que não puderem ser classificados são alimentados ao segundo classificador. Este possui alta precisão e, logo, maior custo, mas com menos requisições de vazão.
3. *Reconfigurable Cascade Chain* – Foi projetado para problemas com grandes quantidades de dados, que podem exceder as limitações de hardware. Essa arquitetura propõe uma reconfiguração do FPGA depois do estágio de treino e expande o espaço de design possível. Isso permite a utilização de mais blocos durante as classificação.

A base utilizada para testes foi a *MINIST Dataset*. Comparando com testes prévios em GPU, o design *Heterogeneous Baseline Classifier* processou os dados 7 vezes mais rápido. Os melhores resultados foram obtidos usando *Reconfigurable Cascade Chain*, com um ganho de 20 vezes, isto é, levando apenas 5 que a GPU consumiu.

CAPÍTULO 7

TESTES

Três baterias de testes foram conduzidas ao longo da produção deste trabalho de graduação a fim de ver na prática o impacto dos algoritmos de aprendizagem de máquina quando aplicados em bases de dados com informações de rede. Em um dos testes, a base utilizada foi a supracitada KDD Cup 99. Para os outros, utilizou-se uma série de dados gerados pelo mestrando da PUC-PR Eduardo, orientado pelo Pr. Dr. Altair. Em ambos os casos, os algoritmos foram executados através do Weka.

7.1 Weka

O *Waikato Environment for Knowledge Analysis* (Weka) é uma suíte de aplicações para aprendizagem de máquina e mineração de dados. O software foi desenvolvido em Java na *University of Waikato* e licenciado sob a *GNU General Public License*. Os destaques dessa ferramenta incluem a vasta quantidade de algoritmos implementados, pré-processamento de dados, seleção de atributos e visualização de dados. O Weka funciona como uma interface, permitindo que novos algoritmos em Java sejam produzidos e facilmente executados de forma gráfica e com resultados interativos [?].

7.2 Avaliação de Performance

Gráficos ROC (*Receiver Operating Characteristics*) são comumente usados como um método para visualizar a performance de classificadores e analisar as taxas de acertos e alarmes falsos [?]. Um gráfico ROC baseia-se em apenas duas classes: positivo ou negativo. Em termos de detecção de intrusão, uma conexão pode ser considerada inofensiva (positivo) ou prejudicial (negativa). Para avaliar a precisão de um classificador, duas outras categorias podem ser usadas: verdadeiro ou falso. Quando cruzadas, obtém-se

quatro possíveis resultados, como mostra a tabela 7.1.

	Verdadeiro (T)	Falso (F)
Positivo	TP – Conexão inofensiva é classificada corretamente	FP – Conexão anômala é considerada normal
Negativo	TN – Conexão prejudicial é classificada corretamente	FN – Conexão normal é considerada anômala

Tabela 7.1: My table

Quando se sabe a verdadeira natureza dos casos de teste, é possível determinar a precisão, a taxa de Verdadeiro Positivo (TP_{rate}) e taxa de Falso Positivo (FP_{rate}). É possível inferir que uma das maiores preocupações ao se construir um A-NIDS é a minimização a taxa de Falso Positivo. Teoricamente se 100% das conexões forem consideradas anômalas e bloqueadas, teremos FP_{rate} igual a 0. Por um lado, o sistema estaria bloqueando conexões inofensivas, por outro, estaria com certeza evitando conexões ameaçadores. O cálculo das taxas se dá da seguinte maneira.

$$Precisão = \frac{TP + TN}{P + N}$$

$$TP_{rate} = \frac{TP}{P}$$

$$FP_{rate} = \frac{FP}{N}$$

Essas taxas estão contidas no espaço entre 0 e 1, inclusivo, e são utilizadas para plotar o ROC. A TP_{rate} é usado no eixo y e a FP_{rate} , no eixo x . Portanto, o gráfico ROC elicit a relação entre Verdadeiro Positivo e Falso Positivo.

A ?? mostra uma curva ROC simples com 5 classificadores fictícios: A, B, C, D e E. Cada classificador retorna um único ponto no espaço ROC. Se o ponto estiver localizado na coordenada (0,0), como o classificador A na ??, significa que nenhum caso foi considerado inofensivo. Classificadores que se encontram próximos ao eixo y podem ser considerados "conservadores", uma vez que necessitam de forte evidência para categorizar uma ocorrência como positiva. Em contrapartida, o ponto B, posicionado em (1,1), representa sistemas que não acusaria nenhuma conexão como anômala. Classificadores mais à direita do gráfico podem ser considerados "liberais" pois presumem como positivo mais facilmente.

Um classificador perfeito resultaria no ponto (0,1), onde C se encontra. Isso significaria possuir FP_{rate} de 0% e TP_{rate} de 100%, ou seja, todas as conexões intrusivas serem detectadas e nenhuma conexão normal ser bloqueada pelo sistema. Assim sendo, quanto maior o TP_{rate} e menor o FP_{rate} , mais preciso é o algoritmo. Se um classificador está localizado abaixo da linha diagonal ($y = x$), isto significa que sua performance é pior do que a escolha aleatória de classes. O triângulo inferior direito é geralmente encontrado vazio pois em casos de classificação binária com alta taxa de erro, é possível simplesmente inverter os resultados. Portanto, E (0.8,0.2) seria tão preciso quanto D(0.2,0.8)

7.3 Impacto de modelos representativos

For the purpose of this paper, however, only the default implementation of SVM was used. The initial part of the test consisted on acquiring and dividing the KDD Cup 99. Five different partitionings were made:

1. 10% for training and 90% for testing
1. 10% for training and 90% for testing
1. 10% for training and 90% for testing
1. 10% for training and 90% for testing
1. 10% for training and 90% for testing

Then, for each partitioning, the SVM was used to generate the model and classify the instances. The command used on Weka included a preprocessing using shrinking heuristics, weights of 1, seed of 3, error of 0.001 and the radial basis kernel function.

7.4 Impacto da imprevisibilidade

input. Different approaches were used to compare the proposed algorithm with. The proposed algorithm in [6] had 99.96 accuracy and used only 23 features. This represents a fortunate contrast to other results. The standalone SVM used with Weka achieved 99.64 only in a particular fold, which was in test number 5. Test number 1 resulted in 99.22 accuracy and took around 16 hours to process. Tests number 2, 3 and 4 correctly guessed 99.45, 99.56 and 99.62 respectively. As for the FPGA implementation, the speed gain was very interesting. Tests ran on MNIST Dataset had shown a speed-up of 7x when using the FPGA heterogeneous classifier, when compared to GPU works. Nonetheless, the reconfigurable cascade classifier achieved a 20x speed-up.

7.5 Impacto da seleção de atributos

A series of tests was conducted in order to see in practice the performance of classification algorithms. The idea was to see the impact of the size of the training set related to the

test set and to compare the results with the previously proposed algorithms. The classification method used was a pure SVM, which was ran through Weka.

CAPÍTULO 8

CONCLUSÃO

Neste trabalho foram realizados estudos sobre o tema super-resolução de forma a avaliar sua aplicabilidade em dois cenários. O primeiro em imagens RGB de sequência de vídeo contendo uma pessoa, de forma a fornecer quadros de maior resolução a sistemas biométricos. Segundo em imagens de profundidade com objetos rígidos, a fim de verificar o potencial da aplicação futura com biometria.

Através da codificação de dois algoritmos, um para cada modalidade, mostrou-se que o método, mesmo baseado em um modelo simplificado de observação, permite a obtenção de resultados melhores no aumento da resolução espacial de imagens quando comparado a soluções tradicionais, como a interpolação bicúbica.

A confirmação da eficácia da super-resolução em sequências de vídeo contendo faces indica o potencial de sua aplicação em sistemas biométricos. Podendo tanto diminuir o custo, quanto permitir maior performance.

Em trabalhos futuros espera-se considerar outros tipos de movimento além da translação; tratar oclusões; experimentar e comparar outros métodos de estimação de movimento na etapa de alinhamento; avaliar os resultados obtidos com diferentes métodos de reconstrução; incluir estimação de ruído e desfoque; e quantificar a influência da super-resolução no aumento da performance de sistemas biométricos, como por exemplo, de reconhecimento facial.

BIBLIOGRAFIA

- [1] Remco R. Bouckaert, Eibe Frank, Mark A. Hall, Geoffrey Holmes, Bernhard Pfahringer, Peter Reutemann, e Ian H. Witten. Weka—experiences with a java open-source project. *J. Mach. Learn. Res.*, 11:2533–2541, dezembro de 2010.
- [2] J. J. Davis e A. J. Clark. Data preprocessing for anomaly based network intrusion detection: A review. *Computers Security*, SAC '08, páginas 953–954, New York, NY, USA, 2011. ACM.
- [3] Tom Fawcett. Roc graphs: Notes and practical considerations for researchers. Relatório técnico, Hawlett Packard, 2004.
- [4] Yang Li e Li Guo. An active learning based tcm-knn algorithm for supervised network intrusion detection. *Computers Security*, 26(7-8):459 – 467, 2007.
- [5] M. Papadonikolakis e C.-S. Bouganis. An intelligent algorithm with feature selection and decision rules applied to anomaly intrusion detection. *Applied Soft Computing*, SAC '08, páginas 953–954, New York, NY, USA, 2011. ACM.
- [6] Sandhya Peddabachigari, Ajith Abraham, Crina Grosan, e Johnson Thomas. Modeling intrusion detection system using hybrid intelligent systems. volume 30, páginas 114 – 132, 2007. *Network and Information Security: A Computational Intelligence Approach*. Network and Information Security: A Computational Intelligence Approach.
- [7] Marcela Xavier Ribeiro, Agma J. M. Traina, e Caetano Traina, Jr. A new algorithm for data discretization and feature selection. *Proceedings of the 2008 ACM Symposium on Applied Computing*, SAC '08, páginas 953–954, New York, NY, USA, 2008. ACM.
- [8] C.-Y. Lee S.-W. Lin, K.-C. Ying e Z.-J. Lee. An intelligent algorithm with feature selection and decision rules applied to anomaly intrusion detection. *Applied Soft Computing*, SAC '08, páginas 953–954, New York, NY, USA, 2012. ACM.

- [9] Chih-Fong Tsai, Yu-Feng Hsu, Chia-Ying Lin, e Wei-Yang Lin. Intrusion detection by machine learning: A review. *Expert Systems with Applications*, 36(10):11994 – 12000, 2009.